

Claude Sonnet 4.6

DeepSeek-V3

Gemini 2.5 Flash

GPT-4.1 Mini

F1-Score

0.0

0.2

0.4

0.6

0.8

1.0

Question

1

7

13

19

25

31

37

43

49

55

61

67

73

79

85